

Guia do Projeto - Engenharia de Dados Databricks

Versao atualizada com Bronze, Silver Base, Silver Curated, Gold, Data Marts, Views, Analytics e leitura do escopo do desafio final.

Este guia consolida a arquitetura e o plano de execucao do projeto camara-data-pipeline. A atualizacao mantem a base do guia anterior e preserva os 22 topicos originais, ajustando apenas os dados que ficaram defasados em relacao ao projeto real e as decisoes tomadas durante a criacao dos notebooks.

Resumo da decisao: dimensoes e fatos permanecem na camada Gold. A Silver continua separada em 01_base e 02_curated. Data Marts, Views e produtos analiticos tambem ficam na Gold/Analytics, seguindo a convencao dm_, ft_, am_ e vw_, sem misturar modelagem dimensional com tratamento tecnico.

Atualizacao desta versao: o projeto enviado possui Bronze com notebooks de ingestao por API e arquivos, Silver Base com 14 notebooks, Silver Curated com 13 notebooks, Gold com dimensoes e fatos ja implementados e Analytics com notebooks analiticos de CEAP, frentes, eventos, votacoes, engajamento, parliamentary intelligence e validacoes.

1. Objetivo

Definir as diretrizes, padroes, arquitetura e escopo da solucao de dados desenvolvida no Databricks, utilizando a API de Dados Abertos da Camara dos Deputados. O objetivo e construir uma solucao ponta a ponta com escalabilidade, rastreabilidade, qualidade de dados, reprocessamento e clareza analitica.

Complemento atualizado: alem do objetivo original, o projeto passou a demonstrar uma solucao real de Data Lakehouse com PySpark e Delta Lake, incluindo lineage completo, padronizacao profissional dos notebooks, observabilidade operacional, logs com volumes lidos, gravados e descartados, validacoes explicitas, tabelas rejeitadas quando aplicavel e separacao clara entre preparacao tecnica, curadoria, modelagem dimensional e produtos analiticos.

2. Principios do Projeto

- Databricks como ambiente principal de execucao.
- GitHub como repositorio de versionamento, documentacao e entrega.
- Arquitetura medalhao: bronze, silver_base, silver_curated, gold e analytics.
- Uso de PySpark, Spark SQL e Delta Lake.
- Logging obrigatorio, controle de execucao e reuso de codigo.
- Foco em solucao produtiva, nao apenas notebooks isolados.
- Reprocessamento possivel a partir da Bronze e reconstrucao das camadas derivadas.
- Preferencia por recursos nativos do PySpark para transformacao e analise.

Complemento atualizado: os notebooks seguem padrao profissional com header institucional, imports, configuracoes, leitura, padronizacao, regras de negocio, qualidade, persistencia Delta e logging final. As celulas de debug devem ser removidas antes do commit. DataFrames intermediarios devem ter nomes semanticos. Validacoes criticas devem usar raise Exception. O projeto nao adota try/except multi-celula nem monitoring.quality_log como obrigatorio nesta etapa.

3. Arquitetura

A arquitetura adotada segue o padrao medalhao com refinamento progressivo dos dados.

Camada	Responsabilidade	Tipo de saida
bronze	Ingestao bruta da API e/ou arquivos, preservando dados originais, metadados, endpoint, batch_id, hash e auditoria.	Tabelas raw Delta e base de replay.
silver_base	Parsing, tipagem, padronizacao, deduplicacao tecnica, flags de qualidade, validacoes estruturais e descarte controlado.	Tabelas limpas por endpoint/familia de endpoint.
silver_curated	Entidades reutilizaveis, regras leves, enriquecimentos, fallbacks, padronizacao textual e preparacao para Gold.	Tabelas de negocio consolidadas.
gold	Modelo estrela com dimensoes, fatos, marts e views. Objetos dm_, ft_, am_ e vw_.	Produtos dimensionais e analiticos.
analytics	Consumo, exploracao, validacoes finais, analises e notebooks executivos.	Consultas, dashboards, relatorios e validacoes.

Ajuste atualizado: a Silver Base deixou de ser apenas limpeza minima e passou a ter validacoes estruturais explicitas, deduplicacao deterministica, flags de qualidade quando aplicavel e preservacao obrigatoria do lineage Bronze. A Silver Curated consolida entidades e prepara a modelagem, mas nao cria fatos ou dimensoes finais. A Gold, conforme o projeto atual, ja contem dimensoes e fatos fisicos implementados.

4. Modelagem

O padrao adotado e o esquema estrela. Fatos nao se relacionam diretamente entre si. As tabelas fato se conectam apenas as dimensoes reutilizaveis. Essa decisao foi mantida durante a evolucao do projeto.

Prefixo	Tipo	Exemplo no projeto
dm_	Dimensoes	gold.dm_data, gold.dm_legislatura, gold.dm_partido, gold.dm_deputado, gold.dm_proposicao, gold.dm_orgao, gold.dm_gabinete, gold.dm_fornecedor, gold.dm_evento, gold.dm_frente, gold.dm_uf, gold.dm_tipo_despesa, gold.dm_bancada, gold.dm_responsavel_ceap
ft_	Fatos	gold.ft_despesas_ceap, gold.ft_votacoes, gold.ft_votos, gold.ft_orientacoes_bancada, gold.ft_atividade_parlamentar, gold.ft_presenca_eventos, gold.ft_frentes_membros
am_	Data Marts analiticos	Produtos agregados construidos na etapa Analytics/Gold para CEAP, frentes, eventos, votacoes e engajamento.
vw_	Views analiticas	Views para consumo final, ranking, anomalias, calendario, alinhamento e indicadores.

Ajuste atualizado: a Gold nao esta mais apenas iniciada com tres fatos. O projeto atual possui dimensoes conformadas, fatos principais e notebooks de analytics. A construcao das dimensoes permanece na Gold, a partir das entidades confiaveis preparadas na Silver Curated.

5. Nomenclatura

- Minusculo, snake_case e sem acentos.
- Colunas no padrao mnemonico_tipo_campo.
- Exemplos: dept_tx_nome, desp_vl_valor, evt_dt_data, vot_id_votacao.
- Chaves tecnicas: sk_entidade quando aplicavel.
- Chaves de negocio preservadas com id/cd conforme origem.
- FKs na Gold apontam para dimensoes conformadas.

Tipo	Significado
id	Identificador de origem ou negocio
cd	Codigo
tx	Texto
dt	Data
ts	Timestamp
vl	Valor
qt	Quantidade
fl	Flag
sk	Surrogate key
nr	Numero
sg	Sigla

Ajuste atualizado: foi mantido o padrao semantico para DataFrames intermediarios. Evitar df1, df2 e tmp_df. Preferir df_standardized, df_validated, df_curated, df_enriched, df_filtered, df_fact, df_dimension e df_discarded conforme a etapa logica do processamento.

6. Regras de Modelagem

- Sem relacionamento fato-fato.
- Dimensoes reutilizaveis e conformadas.
- Definicao clara de grao para cada fato.
- Colunas herdadas mantem o mesmo nome quando atravessam camadas, salvo quando houver regra de negocio clara.
- Fatos em nivel transacional sempre que possivel; marts para agregacoes analiticas.
- Silver prepara entidades confiaveis; Gold cria objetos finais dm_, ft_, am_ e vw_.
- Fatos devem carregar chaves para dimensoes e metricas coerentes com o grao definido.
- Linhagem bronze_* deve ser preservada quando for relevante para auditoria do fato ou dimensao.

Ajuste atualizado: a regra evita misturar tratamento tecnico, curadoria e modelagem dimensional na mesma camada. A Gold atual ja materializa dimensoes como deputado, partido, fornecedor, orgao, frente, proposicao, data e responsavel CEAP, e fatos como despesas CEAP, votos, votacoes, orientacoes, presenca em eventos, atividade parlamentar e membros de frentes.

7. Estrutura no Databricks

Estrutura atual alinhada ao projeto enviado:

Pasta	Conteudo
00_setup	Criacao de schemas, tabelas de controle, testes administrativos e validacoes de tabelas de qualidade.
01_bronze	Notebooks de ingestao por API e por arquivos para deputados, detalhes, frentes, membros, eventos, proposicoes, despesas, orgaos, votacoes, orientacoes, votos, legislaturas e validacao Bronze.
02_silver/01_base	14 notebooks Silver Base: deputados, detalhes, frentes, membros, proposicoes, despesas, orgaos, orgaos_membros, votacoes, orientacoes, votos, legislaturas e fornecedores.
02_silver/02_curated	13 notebooks Silver Curated: deputados, frentes, eventos, membros, proposicoes, despesas, orgaos, orgaos_membros, votacoes, orientacoes, votos, legislaturas e fornecedores.
03_gold	Schema Gold, 14 dimensoes e 7 fatos implementados.
04_analytics	CEAP, frentes, eventos, votacoes, engajamento, parliamentary intelligence e validacoes.
90_common	api_client, pagination, logger, table_logger, bronze_writer, config e cnpj_utils.
99_jobs	Espaco reservado para orquestracao e jobs.

Ajuste atualizado: embora o guia anterior sugerisse subpastas dentro da Gold, o projeto atual concentra os scripts Gold diretamente em 03_gold com numeracao sequencial. Essa organizacao esta valida, desde que a documentacao deixe claro quais scripts constroem dimensoes, fatos, marts e views.

8. Reuso de Codigo

Funcoes reutilizaveis permanecem em 90_common. A regra e evitar duplicacao entre notebooks de ingestao, transformacao e carga.

Modulo	Uso no projeto
api_client	Chamadas HTTP e tratamento de resposta da API.
pagination	Paginacao com retry e controle de volume.
logger / table_logger	Logs tecnicos, eventos do pipeline e persistencia operacional.
config	Parametros globais e configuracoes reutilizaveis.
bronze_writer	Escrita padronizada da Bronze em Delta.
cnpj_utils	Funcoes auxiliares para padronizacao/validacao de CNPJ no contexto de fornecedores.

Ajuste atualizado: o reuso tambem orienta validacao, escrita Delta, logging via log_pipeline_event e padronizacao das estruturas dos notebooks. O objetivo e manter notebooks enxutos, legiveis, consistentes e auditaveis.

9. Logging

- Registrar inicio e fim de cada execucao.
- Registrar volume lido, volume escrito e volume descartado.
- Registrar erros com endpoint, tabela destino e batch_id.
- Persistir logs em estrutura de monitoramento, especialmente monitoring.pipeline_log ou monitoring.execution_log.
- Padronizar PIPELINE_NAME, LAYER, SOURCE_TABLE/TABLE_NAME e TARGET_TABLE quando aplicavel.

Evento	Finalidade
job_started	Inicio da execucao com contexto do pipeline, camada, origem e destino.
quality_validation	Registro das validacoes de qualidade executadas.
persist_started	Inicio da escrita Delta.
persist_finished	Fim da escrita Delta.
job_finished	Conclusao com records_read, records_written e records_discarded.
job_failed	Falha da execucao com mensagem de erro e contexto.

Ajuste atualizado: o projeto padronizou records_read, records_written e records_discarded. O layer deve ser informado por variavel LAYER. A contagem de descartados passou a ser parte obrigatoria da comunicacao de qualidade e execucao.

10. Qualidade de Dados

- Validacao de nulos em chaves e campos obrigatorios.
- Deduplicacao por chave natural, chave composta ou hash.
- Controle de tipos e schema.
- Controle de volume por execucao.
- Rastreabilidade por batch_id, ingestion timestamp, source endpoint, source file e hash.
- Flags *_valida para datas, periodos, e-mails e regras especificas quando aplicavel.

- Descarte controlado com `df_discarded` e motivo de rejeicao quando a regra exigir.

- Falhas criticas interrompem o pipeline com raise `Exception`.

Ajuste atualizado: as validacoes da Silver Base foram fortalecidas. Foi decidido nao implementar `try/except` multi-celula nem `monitoring.quality_log` por enquanto. O `quality_log` permanece como evolucao futura documentada; a implementacao atual prioriza validacoes explicitas no notebook e logging operacional.

11. Carga Incremental

A carga incremental deve ser aplicada quando o endpoint ou o volume justificar. O desafio permite estrategias como hash de payload, uso de ID, controle de data ou controle de offset. No projeto, a recomendacao continua sendo combinar controle por endpoint com metadados de execucao.

Estrategia	Aplicacao recomendada	Saida esperada
Controle por ano ou periodo	Despesas, proposicoes e votacoes com grande volume historico.	Reprocessamento seletivo por particao.
Controle por ID	Votacoes, proposicoes, frentes, eventos e detalhes relacionados.	Evitar duplicidade e permitir append seguro.
Hash do payload	Quando o registro pode mudar sem alterar ID.	Identificar alteracao e suportar CDC.
Tabela de controle	<code>monitoring</code> ou <code>config.ingestion_control</code> .	Replay, auditoria e recuperacao.
Carga por arquivo	Arquivos CSV/JSON disponibilizados para proposicoes, despesas, orgaos, votacoes, orientacoes e votos.	Reprocessamento controlado por <code>source_file</code> , ano e <code>batch_id</code> .

No desafio, despesas CEAP exigem ingestao incremental de `/deputados/{id}/despesas` com paginacao. Para votacoes, o desafio opcional sugere job frequente com controle de offset por ID. Para proposicoes, o desafio opcional sugere CDC de tramitacao com SCD Type 2.

Ajuste atualizado: enquanto a camada incremental completa nao for evoluída, o projeto mantem rastreabilidade por `batch_id`, endpoint, `source_file`, ano de referencia, hash de registro e parametros de execucao para permitir replay e comparacao entre cargas.

12. Monitoramento

As execucoes devem ser registradas em tabelas de monitoramento para permitir rastreabilidade, SLA, auditoria e investigacao de falhas.

Tabela	Finalidade	Status no projeto
<code>monitoring.pipeline_log</code>	Eventos tecnicos do pipeline: inicio, fim, erro, volumes, duracao e contexto.	Prioridade atual de observabilidade.
<code>config.ingestion_control</code>	Controle incremental por endpoint, parametros, watermark, ultimo ID ou hash.	Documentado como mecanismo de evolucao/controle.
<code>monitoring.quality_log</code>	Resultado estruturado das validacoes de qualidade: nulos, duplicidade, volume e schema.	Evolucao futura; nao obrigatorio nesta etapa.
Tabelas rejeitadas	Persistencia de registros descartados quando a regra de negocio/qualidade justificar.	Premissa adotada nas camadas Silver quando aplicavel.

Ajuste atualizado: a implementacao atual prioriza validacoes explicitas no notebook, `records_discarded` e logging operacional. O `quality_log` nao foi imposto para evitar complexidade desnecessaria nesta fase.

13. Resiliencia e Recuperacao

Todos os pipelines devem permitir reprocessamento. A arquitetura deve suportar retry, replay, reexecucao por periodo e analise de incidentes.

- Retry em chamadas de API.

- Gravacao idempotente quando possivel.

- Uso de `batch_id` para rastrear execucao.

- Reprocessamento por ano, mes, deputado, votacao, arquivo ou endpoint.

- Bronze como fonte de replay.

- Silver Base recriavel a partir da Bronze.

- Silver Curated recriavel a partir da Silver Base.

- Gold recriavel a partir da Silver Curated validada.

- Analytics recriavel a partir dos objetos Gold.

Ajuste atualizado: em caso de erro na Silver Base ou Curated, validar primeiro lineage, registros descartados e regras de qualidade aplicadas. Em caso de erro na Gold, recriar a tabela a partir da Silver Curated validada, evitando uso direto da

Bronze para produtos analiticos finais.

14. Perguntas de Negocio e Escopo Analitico

O escopo do guia antigo permanece valido, agora alinhado ao desafio e ao projeto atual.

Eixo	Perguntas de negocio	Tabelas base/produtos
Atlas das Frentes	Quais frentes estao ativas? Quais tem maior diversidade partidaria? Quais deputados participam de mais frentes?	frentes, frentes_membros, deputados, deputados_detalhes, legislaturas, gold.ft_frentes_membros, gold.dm_frente, gold.dm_deputado, gold.dm_partido
Eventos Legislativos	Qual a taxa de presenca? Ha semanas sem atividade? Ha calendario futuro?	eventos, orgaos, orgaos_membros, deputados, gold.ft_presenca_eventos, gold.dm_evento, gold.dm_orgao, gold.dm_data
Votacoes	Deputados de uma mesma frente votam alinhados? Ha divergencia dentro do partido?	votacoes, votacoes_votos, votacoes_orientacoes, frentes_membros, gold.ft_votos, gold.ft_votacoes, gold.ft_orientacoes_bancada
Despesas CEAP	Quem mais gasta? Quais fornecedores concentram pagamento? Existem anomalias por categoria e UF?	despesas, fornecedores, deputados, gold.ft_despesas_ceap, gold.dm_fornecedor, gold.dm_tipo_despesa
CPIs	Qual o ciclo de vida? Quais geraram proposicoes? Quais ultrapassaram prazo?	orgaos, eventos, proposicoes, orgaos_membros; recorte possivel, nao prioridade maxima.
Engajamento Parlamentar	Quem tem maior presenca? Quem mais falta? Como evolui o engajamento?	eventos, votacoes_votos, deputados, proposicoes, gold.ft_atividade_parlamentar, analytics de engajamento.

Ajuste atualizado: os eixos prioritarios permanecem CEAP, deputados, frentes, eventos e votacoes. CPIs continuam como recorte possivel. A camada Analytics ja contem notebooks especificos para CEAP, frentes, eventos, votacoes, engajamento, parliamentary intelligence e validacoes.

15. Entregaveis do Projeto

Os entregaveis devem evidenciar a solucao de engenharia e tambem a capacidade analitica solicitada pelo desafio.

Categoria	Entregavel
Engenharia	Pipeline funcional em Databricks, com PySpark, Delta Lake, logging, reprocessamento, ingestao por API e suporte a arquivos.
Arquitetura	Diagrama/descricao medalhao com bronze, silver_base, silver_curated, gold e analytics.
Modelagem	Dimensoes e fatos na Gold, com grao documentado e separacao entre dm_ e ft_.
Qualidade	Validacoes de nulos, duplicidade, tipo, volume, schema, flags de qualidade e records_discarded.
Analytics	Produtos de CEAP, frentes, eventos, votacoes, CPIs quando possivel, engajamento e parliamentary intelligence.
Documentacao	README, guia tecnico, runbook, decisoes tecnicas e instrucoes de execucao.
Evidencias atuais	Bronze, Silver Base, Silver Curated, Gold e Analytics ja estruturados no repositorio enviado.

Ajuste atualizado: tambem entram como evidencias o padrao de lineage, notebooks revisados, logging com records_discarded, tabelas rejeitadas quando aplicavel, Gold com dimensoes/fatos e Analytics com produtos analiticos.

16. Estrategia de Execucao

Ordem recomendada de construcao e validacao:

Ordem	Etapas	Objetivo
1	Bronze	Garantir ingestao e persistencia bruta.
2	Silver Base	Limpar, tipar, padronizar, deduplicar e validar.
3	Revisao Silver Base	Conferir lineage, descartes, flags e padrao dos notebooks.
4	Silver Curated	Criar entidades reutilizaveis, regras leves, enriquecimentos e fallbacks.
5	Revisao Curated	Validar consistencia das entidades preparadas para Gold.
6	Gold Dimensions	Criar dimensoes conformadas.
7	Gold Facts	Criar fatos com grao claro.
8	Gold Marts/Views	Criar am_ e vw_ para perguntas de negocio.
9	Analytics	Criar notebooks de validacao, analise e apresentacao.

Ajuste atualizado: no projeto atual, Silver Base e Silver Curated ja foram amplamente implementadas; Gold possui dimensoes e fatos; Analytics possui notebooks analiticos. A prioridade passa a ser consolidar documentacao, validar aderencia ao desafio e refinar views/marts finais.

17. Consideracao Final

Este projeto deve ser tratado como uma solucao real de Engenharia de Dados, com foco em qualidade, organizacao, governanca, rastreabilidade e clareza analitica. A entrega deve demonstrar tanto dominio tecnico de Databricks e PySpark quanto capacidade de transformar dados publicos em produtos analiticos reutilizaveis.

Ajuste atualizado: a solucao comunica maturidade de Data Lakehouse, observabilidade, lineage, reprocessamento, validacoes explicitas, separacao correta entre preparacao tecnica, curadoria e modelagem analitica, alem de capacidade de gerar insights de negocio sobre CEAP, frentes, eventos, votacoes e engajamento parlamentar.

18. Saidas Esperadas por Camada

Esta secao traduz o desafio em tabelas fisicas e produtos de dados, atualizada conforme o projeto enviado.

Camada	Exemplos de tabelas ou objetos	Observacao
bronze	deputados, deputados_detalhes, frentes, frentes_membros, eventos, proposicoes, despesas, orgaos, orgaos_membros, votacoes, votacoes_orientacoes, votacoes_votos, legislaturas e cargas por arquivo.	Camada existente, com ingestao por API e notebooks b_ para arquivos.
silver_base	base_deputados, base_deputados_detalhes, base_frentes, base_frentes_membros, base_proposicoes, base_despesas, base_orgaos, base_orgaos_membros, base_votacoes, base_votacoes_orientacoes, base_votacoes_votos, base_legislaturas, base_fornecedores.	14 notebooks implementados; uma tabela limpa por endpoint ou entidade tecnica.
silver_curated	curated_deputados, curated_frentes, curated_eventos, curated_frentes_membros, curated_proposicoes, curated_despesas, curated_orgaos, curated_orgaos_membros, curated_votacoes, curated_votacoes_orientacoes, curated_votacoes_votos, curated_legislaturas, curated_fornecedores.	13 notebooks implementados; entidades de negocio reutilizaveis.
gold - dm_	dm_data, dm_legislatura, dm_partido, dm_deputado, dm_proposicao, dm_orgao, dm_gabinete, dm_fornecedor, dm_evento, dm_frente, dm_uf, dm_tipo_despesa, dm_bancada, dm_responsavel_ceap.	Dimensoes conformadas implementadas.
gold - ft_	ft_despesas_ceap, ft_votacoes, ft_votos, ft_orientacoes_bancada, ft_atividade_parlamentar, ft_presenca_eventos, ft_frentes_membros.	Fatos com grao analitico definido.
analytics	gold_ceap_analytics, gold_frentes_analytics, gold_eventos_analytics, gold_votacoes_analytics, gold_engajamento_analytics, gold_parliamentary_intelligence, validations.	Produtos analiticos e validacoes finais.

19. Mapa de Notebooks Recomendado

Mapa atualizado conforme os arquivos existentes no projeto enviado.

Pasta	Notebooks existentes / recomendados
00_setup	00_create_schemas.py; 01_create_control_tables.py; 90_admin_test_api_connection.py; 91_admin_reset_environment.py; 92_admin_check_quality_tables.py
01_bronze	01_ingest_deputados.py; 02_ingest_deputados_detalhes.py; 03_ingest_frentes.py; 04_ingest_eventos.py; 05_ingest_frentes_membros.py; 06_ingest_proposicoes.py; 06b_ingest_proposicoes_file.py; 07_ingest_despesas.py; 07b_ingest_despesas_file.py; 08_ingest_orgaos.py; 09_ingest_orgaos_membros.py; 09b_ingest_orgaos_membros_file.py; 10_ingest_votacoes.py; 10b_ingest_votacoes_file.py; 11_ingest_votacoes_orientacoes.py; 11b_ingest_votacoes_orientacoes_file.py; 12_ingest_votacoes_votos.py; 12b_ingest_votacoes_votos_file.py; 13_ingest_legislaturas.py; 99_validate_bronze.py
02_silver/01_base	01_base_deputados.py; 02_base_deputados_detalhes.py; 03_base_frentes.py; 04_base_eventos.py; 05_base_frentes_membros.py; 06_base_proposicoes.py; 07_base_despesas.py; 08_base_orgaos.py; 09_base_orgaos_membros.py; 10_base_votacoes.py; 11_base_votacoes_orientacoes.py; 12_base_votacoes_votos.py; 13_base_legislaturas.py; 14_base_fornecedores.py
02_silver/02_curated	01_curated_deputados.py; 03_curated_frentes.py; 04_curated_eventos.py; 05_curated_frentes_membros.py; 06_curated_proposicoes.py; 07_curated_despesas.py; 08_curated_orgaos.py; 09_curated_orgaos_membros.py; 10_curated_votacoes.py; 11_curated_votacoes_orientacoes.py; 12_curated_votacoes_votos.py; 13_curated_legislaturas.py; 14_curated_fornecedores.py
03_gold	00_create_gold_schema.py; 01_build_dm_tempo.py; 02_build_dm_legislatura.py; 03_build_dm_partido.py; 04_build_dm_deputado.py; 05_build_dm_proposicao.py; 06_build_dm_orgao.py; 07_build_dm_gabinete.py; 08_build_dm_fornecedor.py; 09_build_dm_evento.py; 10_build_dm_frente.py; 11_build_dm_uf.py; 12_build_dm_tipo_despesa.py; 13_build_dm_bancada.py; 14_build_dm_responsavel_ceap.py; 15_build_ft_despesas_ceap.py; 16_build_ft_votacoes.py; 17_build_ft_votos.py; 18_build_ft_orientacoes_bancada.py; 19_build_ft_atividade_parlamentar.py; 20_build_ft_presenca_eventos.py; 21_build_ft_frentes_membros.py
04_analytics	01_build_gold_ceap_analytics.py; 02_build_gold_frentes_analytics.py; 03_build_gold_eventos_analytics.py; 04_build_gold_votacoes_analytics.py; 05_build_gold_engajamento_analytics.py; 06_build_gold_parliamentary_intelligence.py; 90_validations.py

Ajuste atualizado: os notebooks devem continuar seguindo header institucional, imports, configuracoes, leitura, padronizacao, regras de negocio, qualidade, persistencia Delta e logging final. Comentarios devem refletir a camada correta, por exemplo Persist Silver Base Delta table, Persist Silver Curated Delta table ou Persist Gold Delta table.

20. Traducao do Desafio em Produtos de Dados

Tema do desafio	Produto Gold principal	Marts, views e analytics
Atlas das frentes parlamentares	ft_frentes_membros + dm_frente + dm_deputado + dm_partido + dm_uf + dm_legislatura	gold_frentes_analytics; diversidade partidaria; deputados em mais frentes; sobreposicao de membros; evolucao por legislatura.
Calendario analitico de eventos legislativos	ft_presenca_eventos + dm_evento + dm_orgao + dm_data	gold_eventos_analytics; densidade semanal; semanas sem atividade; eventos futuros; taxa de presenca.
Correlacao entre frentes e votacoes	ft_votos + ft_votacoes + ft_frentes_membros + dm_deputado + dm_partido	gold_votacoes_analytics; alinhamento entre frente e partido; divergencia partidaria.
Raio-X CEAP	ft_despesas_ceap + dm_deputado + dm_fornecedor + dm_tipo_despesa + dm_data + dm_responsavel_ceap	gold_ceap_analytics; top gastos; fornecedor; categoria; UF; anomalias; suspeita de CNPJ quando aplicavel.

Tema do desafio	Produto Gold principal	Marts, views e analytics
Auditoria de CPIs	Recorte possivel via dm_orgao, eventos, proposicoes e membros.	Pode ficar como evolucao documentada caso nao haja tempo para timeline completa.
Engajamento parlamentar	ft_atividade_parlamentar + ft_presenca_eventos + ft_votos + dm_deputado + dm_data	gold_engajamento_analytics; score de engajamento; absenteismo; serie temporal; comparativos.

Ajuste atualizado: o projeto evoluiu para uma camada de Parliamentary Intelligence, com análises avançadas de perfil parlamentar, transparência, eficiência, alinhamento partidário, comportamento de gastos e engajamento.

21. Priorizacao Realista para Entrega

Considerando as tabelas Bronze já disponíveis e o projeto atual, a priorizacao segura continua focada em CEAP, deputados, frentes, eventos e votacoes. CPIs permanecem como recorte possivel ou evolucao documentada.

Prioridade	Entrega	Status / motivo
Concluida/Alta	Silver Base completa	Projeto atual possui 14 notebooks Silver Base, incluindo legislaturas e fornecedores.
Concluida/Alta	Silver Curated consolidada	Projeto atual possui 13 notebooks Curated para entidades reutilizaveis.
Concluida/Alta	Dimensoes centrais	Gold possui dm_data, dm_legislatura, dm_partido, dm_deputado, dm_fornecedor, dm_orgao, dm_frente, dm_uf e outras dimensoes.
Concluida/Alta	Fatos principais	Gold possui ft_despesas_ceap, ft_votacoes, ft_votos, ft_orientacoes_bancada, ft_atividade_parlamentar, ft_presenca_eventos e ft_frentes_membros.
Alta	Analytics CEAP e anomalias	Atende diretamente ao eixo CEAP e ao requisito de deteccao de padroes/anomalias.
Media/Alta	Analytics de frentes, eventos, votacoes e engajamento	Atende aos principais produtos solicitados no desafio.
Opcional	SCD Type 2 de proposicoes ou CDC de tramitacao	Demonstra maturidade, mas pode ficar como evolucao documentada.
Opcional	Streaming de votacoes	Desafio opcional; pode ser registrado no roadmap.

Ajuste atualizado: a prioridade alta da Silver Base não é mais pendente. A próxima prioridade prática é revisar aderência final ao desafio, estabilizar Analytics, documentar runbook, evidenciar lineage e refinar as views/marts finais.

22. Runbook Resumido

Incidente	Acao recomendada
Falha na API	Reexecutar notebook com mesmo batch_id ou novo batch_id, mantendo controle de periodo, endpoint e parametros.
Erro de schema	Parar execucao, registrar erro, comparar schema Bronze anterior com atual e ajustar Silver Base.
Duplicidade	Reprocessar Silver Base com regra de deduplicacao por chave natural, chave composta ou hash.
Volume inesperado	Validar parametros de ingestao, paginacao, filtros por ano/periodo e arquivos de origem.
Registros descartados acima do esperado	Consultar df_discarded/tabela de rejeitados, revisar flags de qualidade e motivos de rejeicao.
Erro de lineage	Validar preservacao de bronze_ts_ingestao, bronze_dt_ingestao, bronze_tx_endpoint, bronze_id_origem, bronze_id_batch, bronze_tx_record_hash, bronze_tx_source_file e bronze_nr_ano_referencia quando aplicavel.
Falha na Gold	Recrutar fato ou dimensao a partir da Silver Curated validada, preservando Bronze como fonte de replay indireta.
Falha em Analytics	Revalidar dependencias Gold, conferir grao das tabelas e reexecutar notebook analitico correspondente.

Decisao final: a Silver não deve criar as dimensoes e fatos finais. A Silver prepara entidades confiáveis. A Gold cria dm_, ft_, am_ e vw_. Essa separacao deixa a solucao mais clara, escalavel e aderente ao que o desafio solicita.

Ajuste atualizado: em caso de erro em Silver Base ou Curated, validar primeiro lineage, registros descartados e regras de qualidade aplicadas. Em caso de erro na Gold, recrutar a tabela a partir da Silver Curated validada, evitando uso direto da Bronze para produtos analiticos finais. O projeto atual já possui objetos suficientes para evidenciar engenharia, modelagem, qualidade, resiliencia e analise de negocio.